

* 주의: axis랑 p랑 무관하다.

유선점-2 벡터의 거리...?

① norm의 정의 (수학적으로)

norm은 기본적으로 벡터공간의 함수이다.

벡터공간의 예제) $\mathbb{R}^2, \mathbb{R}^3, 2 \times 2$ matrix 모여둔 공간 등...

$\|\cdot\|$ (norm) 이 함수를 f 라고 하면.

$$f: V \rightarrow [0, \infty)$$

- i) $f(ax) = a f(x)$
- ii) $f(x+y) \leq f(x) + f(y)$
- iii) $f(x) = 0 \iff x = 0$
- iv) $f(x) \geq 0$

이 조건을 다 만족시키면 'norm 함수'이다.

② L_p -norm이란?

수많은 norm들 중에서 하나... ☆☆☆

$$\|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}$$

$p: 0 \sim \infty$

$$x = (x_1, x_2, \dots, x_n)$$

$p=2$

$$= \sqrt{(x_1)^2 + (x_2)^2 + \dots + (x_n)^2}$$

$$(0, 0, \dots, 0) \iff (x_1, x_2, \dots, x_n)$$

$p=1$ $d = (|x_1| + |x_2| + |x_3| + \dots + |x_n|)$

★ L_p -norm의 정의 (암기하자!)

$$\|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}$$

★ 그리고 L_0, L_1, L_2, L_∞ norm은 꼭 알아야 함! ★

L_1 -norm
↑
 p
따라서,

그러고 $x = (x_1, x_2, \dots, x_n)$ 라고 하면

$$L_0\text{-norm: } \|x\|_0 = \underbrace{(|x_1|^0 + |x_2|^0 + \dots + |x_n|^0)}_{(\text{불가능}) \dots \dots}$$

$$\left(\frac{1}{0}\right) = \infty ?$$

≡ 0이 아님것의 개수!

(이라 0은 정의가 잘 안됨에서
아름답고 처리)

ex) $d = (1, 0, 1)$ 의 L_0 -distance = 2

$(0, 0, 2)$ → 1


L_1 -norm : $\|x\|_1 = |x_1| + |x_2| + \dots + |x_n|$
= 절대값의 합!

L_2 -norm : $\|x\|_2 = \sqrt{|x_1|^2 + \dots + |x_n|^2}$


= 우리가 아는 일반적인 길이.

L_∞ -norm : $\|x\|_\infty = \left(|x_1|^\infty + \dots + |x_n|^\infty \right)^{\frac{1}{\infty}}$

= $\max(x_k)$



여기서 β 를 찾는건 쉽지만...



$$a \cdot x + b \cdot y + c \cdot z + d = 0$$

즉, β 는 변수가 3개.

\Rightarrow 상수가 아닌 행렬로 문제를 풀 필요를 느낀다.

$$\beta = \begin{bmatrix} a \\ b \\ c \end{bmatrix}$$

선형회귀의 목적 L_2 -distance의 최소화.

*가정: 현재 d 차원이다. 즉, $\beta = (\beta_1, \beta_2, \beta_3, \dots, \beta_k, \dots, \beta_d)$

현재 data들은 y 로 정의된다. $y = (y_1, y_2, \dots, y_d)$

여러한 평면위의 점은 $x\beta$ 로 표현된다.

$$L_2\text{-distance} = \|y - x\beta\|_2$$

$$(L_2\text{-distance} : \|x\|_2 = (x_1^2 + \dots + x_d^2)^{\frac{1}{2}} = \left(\sum_{k=1}^d |x_k|^2 \right)^{\frac{1}{2}}$$

$$= \left(\sum_{k=1}^d (y_k - x_k \beta_k)^2 \right)^{\frac{1}{2}}$$

β_k 에 대해 미분하면, $\partial \left(\sqrt{(y_1 - x_1 \beta_1)^2 + \dots + (y_k - x_k \beta_k)^2 + \dots + (y_d - x_d \beta_d)^2} \right)$

$\beta = N$ 개

$$\partial(\beta_k)$$

$$(x^a)' = (a x^{a-1}) \text{ 이므로,}$$

$$\frac{\partial L}{\partial \beta_k} = \frac{1}{2} \left(\|y - x\beta\|^2 \right)^{-\frac{1}{2}} \times (y_k - x_k \beta_k) \times (-x_k)$$

우리가 구하는 값은 임의의 β_k 에 대한 편미분이 아니라 β 를 편미분이므로

확장하면,

$$\frac{\partial L}{\partial \beta} = \left(\frac{\partial L}{\partial \beta_1}, \frac{\partial L}{\partial \beta_2}, \dots, \frac{\partial L}{\partial \beta_d} \right)$$

$$= \left(\frac{-x_1 (y_1 - x_1 \beta_1)}{\|y - x\beta\|_2}, \frac{-x_2 (y_2 - x_2 \beta_2)}{\|y - x\beta\|_2}, \dots, \frac{-x_d (y_d - x_d \beta_d)}{\|y - x\beta\|_2} \right)$$

$$= \left(\frac{-x^T (y - x\beta)}{\|y - x\beta\|_2} \right)$$

* N 은 차원이 커지며 방지하는
항이 커지므로

표준화가 있다! (normalize).